

1 Постановка задачи

Пусть $\mathbf{x} \in \mathbb{R}^n$ — вектор измерений детекторов, а $\mathbf{y} \in \mathbb{R}^m$ — дискретизированный энергетический спектр нейтронов. В текущей постановке используются $n = 10$ входных каналов и $m = 60$ энергетических бинов. Требуется построить отображение

$$\hat{\mathbf{y}} = f_{\theta}(\mathbf{x}), \quad (1)$$

где f_{θ} — адаптивная нейро-нечёткая система вывода ANFIS с параметрами θ .

При работе с нормализованными измерениями применяется нормировка по сумме:

$$S = \sum_{j=1}^n x_j, \quad \mathbf{x}' = \frac{\mathbf{x}}{S}, \quad \mathbf{y}' = \frac{\mathbf{y}}{S}. \quad (2)$$

Инференс и обучение выполняются в нормализованном пространстве, а при необходимости восстановленный спектр денормализуется как

$$\hat{\mathbf{y}} = S\hat{\mathbf{y}}'. \quad (3)$$

2 Модель реконструкции

Используется ANFIS Sugeno-типа с $R = 50$ правилами и гауссовскими функциями принадлежности. Для r -го правила имеем

$$\text{IF } x_1 \text{ is } A_{r1} \text{ AND } \dots \text{ AND } x_n \text{ is } A_{rn} \text{ THEN } \hat{\mathbf{y}}_r = \mathbf{a}_r^{\top} \mathbf{x} + \mathbf{b}_r. \quad (4)$$

Сила срабатывания правила задаётся произведением функций принадлежности,

$$w_r(\mathbf{x}) = \prod_{j=1}^n \mu_{rj}(x_j), \quad \bar{w}_r(\mathbf{x}) = \frac{w_r(\mathbf{x})}{\sum_{s=1}^R w_s(\mathbf{x}) + \varepsilon}, \quad (5)$$

а итоговый выход модели записывается как

$$\hat{\mathbf{y}} = \sum_{r=1}^R \bar{w}_r(\mathbf{x}) (\mathbf{a}_r^{\top} \mathbf{x} + \mathbf{b}_r). \quad (6)$$

3 Двухэтапная схема обучения

Основная рабочая версия метода использует двухэтапную схему.

На первом этапе выполняется базовая оптимизация параметров модели по средне-квадратичной ошибке:

$$\mathcal{L}_{\text{main}} = \frac{1}{Bm} \sum_{i=1}^B \sum_{k=1}^m (\hat{y}_{ik} - y_{ik})^2. \quad (7)$$

Для устойчивой инициализации структуры применяется глобальная оптимизация PSO.

На втором этапе модель донастраивается на реальных измерениях с SHAP-штрафом интерпретируемости и тихоновским штрафом гладкости спектра. В текущем основном пайплайне 375 реальных измерений делятся в отношении 60% : 20% : 20%, что соответствует разбиению 225/75/75 на обучающую, валидационную и тестовую части. Первая стадия использует 300 объектов для базовой инициализации, а финальная оценка обеих версий проводится на одинаковом тестовом наборе из 75 измерений.

4 SHAP-регуляризация второй стадии

4.1 Градиентная проху-оценка важности

Для мини-батча $\mathbf{X} \in \mathbb{R}^{B \times n}$ вводится скаляризованный отклик

$$s_i = \frac{1}{m} \sum_{k=1}^m \hat{y}_{ik}, \quad g_{ij} = \frac{\partial s_i}{\partial x_{ij}}, \quad u_{ij} = |g_{ij}| |x_{ij}|. \quad (8)$$

После усреднения по батчу получаем вектор важности

$$v_j = \frac{1}{B} \sum_{i=1}^B u_{ij}, \quad \tilde{v}_j = \max\left(v_j, 10^{-6} \max_{\ell} v_{\ell}\right), \quad p_j = \frac{\tilde{v}_j}{\sum_{\ell=1}^n \tilde{v}_{\ell} + \varepsilon}. \quad (9)$$

Вектор $\mathbf{p} = (p_1, \dots, p_n)^{\top}$ используется как дифференцируемая проху-оценка глобальной важности входных каналов.

4.2 Компоненты SHAP-регуляризации

Итоговый SHAP-штраф задаётся как

$$\mathcal{L}_{\text{SHAP}} = w_{\text{cons}} R_{\text{cons}} + w_{\text{spar}} R_{\text{spar}} + w_{\text{faith}} R_{\text{faith}} + w_{\text{stab}} R_{\text{stab}}, \quad (10)$$

где веса w в основной конфигурации вычисляются адаптивно и нормируются по текущим значениям компонент.

Согласованность. Для батча строится средний входной вектор $\bar{\mathbf{x}}$ и маскирующая reference-оценка $\mathbf{q}$, где j -й компонент определяется через замену j -го признака на среднее значение по SHAP-обучающей выборке:

$$q_j = \frac{\max(\psi_j, 0)}{\sum_{\ell=1}^n \max(\psi_{\ell}, 0) + \varepsilon}, \quad \psi_j = |\bar{f}(\bar{\mathbf{x}}) - \bar{f}(\bar{\mathbf{x}}^{(j \leftarrow b_j)})|, \quad (11)$$

где $\bar{f}(\mathbf{x}) = \frac{1}{m} \sum_{k=1}^m f_{\theta,k}(\mathbf{x})$. Тогда

$$R_{\text{cons}} = \frac{\text{MSE}(\mathbf{p}, \mathbf{q}) + \lambda_{\text{JS}} \text{JS}(\mathbf{p} \parallel \mathbf{q})}{1 + \mathcal{L}_{\text{main}}}, \quad \lambda_{\text{JS}} = 0.5. \quad (12)$$

Разреженность. Разреженность поощряет концентрацию важности на небольшом наборе каналов:

$$H(\mathbf{p}) = -\frac{1}{\log n} \sum_{j=1}^n p_j \log(p_j + \varepsilon), \quad (13)$$

$$G(\mathbf{p}) = \frac{2 \sum_{j=1}^n j p_j}{n \sum_{j=1}^n p_j + \varepsilon} - \frac{n+1}{n}, \quad (14)$$

$$R_{\text{spar}} = (H(\mathbf{p}) + \max(0, G_\star - G(\mathbf{p}))^2) \left(\rho \frac{1}{1 + \mathcal{L}_{\text{main}}} + 1 - \rho \right), \quad (15)$$

где в основной конфигурации используются $G_\star = 0.3$ и $\rho = 0.7$.

Достоверность объяснений. Faithfulness сравнивает реальное изменение усреднённого выхода модели с его линейной градиентной аппроксимацией относительно нулевого baseline:

$$s_i = \frac{1}{m} \sum_{k=1}^m \hat{y}_{ik}, \quad s_i^{(0)} = \frac{1}{m} \sum_{k=1}^m f_{\theta,k}(\mathbf{0}), \quad a_i = \sum_{j=1}^n g_{ij} x_{ij}, \quad (16)$$

$$R_{\text{faith}} = \frac{1}{1 + \mathcal{L}_{\text{main}}} \cdot \frac{1}{B} \sum_{i=1}^B \left((s_i - s_i^{(0)}) - a_i \right)^2. \quad (17)$$

Стабильность. В текущей реализации стабильность задаётся через внутрибатчевую дисперсию карты важности:

$$\bar{u}_j = \frac{1}{B} \sum_{i=1}^B u_{ij}, \quad R_{\text{stab}} = \frac{1}{1 + \mathcal{L}_{\text{main}}} \cdot \frac{1}{Bn} \sum_{i=1}^B \sum_{j=1}^n (u_{ij} - \bar{u}_j)^2. \quad (18)$$

4.3 Адаптивная балансировка SHAP-члена

Чтобы SHAP-регуляризация не доминировала над основной задачей, в коде используются экспоненциальное скользящее среднее основной ошибки M_t , целевое отношение SHAP/main и мягкое расписание внешнего коэффициента γ_t :

$$M_t = 0.9M_{t-1} + 0.1\mathcal{L}_{\text{main}}^{(t)}, \quad \eta_t = \eta_0(0.5 + 0.5p_t), \quad \eta_0 = 0.4, \quad (19)$$

где $p_t = t/T$ — относительный прогресс по эпохам второй стадии. Нормированный SHAP-член имеет вид

$$\tilde{\mathcal{L}}_{\text{SHAP}}^{(t)} = c_t s_t \mathcal{L}_{\text{SHAP}}^{(t)}, \quad (20)$$

где множитель s_t удерживает отношение SHAP/main в целевом диапазоне, а $c_t \geq 0.25$ замедляет давление SHAP при отсутствии улучшения основной ошибки. Внешний коэффициент задаётся расписанием

$$\gamma_t = \begin{cases} \gamma_{\text{start}} + (\gamma_{\text{end}} - \gamma_{\text{start}}) \frac{p_t}{r_{\text{warm}}}, & p_t < r_{\text{warm}}, \\ \gamma_{\text{end}}, & p_t \geq r_{\text{warm}}, \end{cases} \quad (21)$$

где $\gamma_{\text{start}} = 0.02$, $\gamma_{\text{end}} = 0.10$, $r_{\text{warm}} = 0.5$.

5 Тихоновская регуляризация гладкости спектра

Для подавления нефизичных локальных осцилляций по энергетической оси используется тихоновская регуляризация второго порядка. Для одного предсказанного спектра $\hat{\mathbf{y}}_i$ вводится оператор

$$(D_2 \hat{\mathbf{y}}_i)_k = \hat{y}_{i,k+2} - 2\hat{y}_{i,k+1} + \hat{y}_{i,k}, \quad k = 1, \dots, m-2. \quad (22)$$

Соответствующий штраф по батчу записывается как

$$R_{\text{Tikh}} = \frac{1}{B(m-2)} \sum_{i=1}^B \sum_{k=1}^{m-2} (\hat{y}_{i,k+2} - 2\hat{y}_{i,k+1} + \hat{y}_{i,k})^2. \quad (23)$$

Во внешнем функционале второй стадии используется

$$\mathcal{L}_{\text{total}}^{(t)} = \mathcal{L}_{\text{main}}^{(t)} + \gamma_t \tilde{\mathcal{L}}_{\text{SHAP}}^{(t)} + \lambda_{\text{Tikh}} R_{\text{Tikh}}^{(t)}, \quad \lambda_{\text{Tikh}} = 2 \cdot 10^{-3}. \quad (24)$$

Таким образом, итоговая модель реализует компромисс между точностью восстановления, интерпретируемостью входных каналов и физически правдоподобной гладкостью спектра.

6 Практическая реализация

Кодовая база поддерживает конфигурируемый выбор входных и выходных колонок через параметры `feature_columns`, `target_columns`, `feature_prefix/feature_count`, `target_prefix/target_count`, а также через индексные диапазоны и регулярные выражения. Это позволяет переносить тот же пайплайн на другие спектрометры и другие схемы дискретизации без модификации логики загрузчика данных.

Для практического применения подготовлены два сервисных сценария: инференс обученной модели по заданному вектору измерений с сохранением восстановленного спектра в виде массива и рисунка, а также Monte Carlo-анализ чувствительности к шумам входных каналов.

7 Экспериментальные результаты

7.1 Сравнение режимов регуляризации

Чтобы понять реальную роль каждой регуляризации, были отдельно обучены четыре полные версии на одном и том же тестовом наборе из 75 измерений: *Vanilla ANFIS*, *Tikhonov-only*, *SHAP-only* и *SHAP + Tikhonov*. Сравнение итоговых метрик приведено в табл. 1.

На текущем наборе данных лучшей по обычным метрикам качества оказалась версия *SHAP-only*. Полная связка *SHAP + Tikhonov* очень близка к ней по MSE и R_{weighted}^2 , но уже не является безусловным лидером по всем критериям. В свою очередь, *Tikhonov-only* также уверенно превосходит baseline и оказывается лишь немного слабее двух SHAP-режимов.

Метрика	Vanilla	Tikhonov-only	SHAP-only	SHAP + Tikhonov
MSE	0.01133	0.01063	0.01060	0.01060
RMSE	0.10643	0.10310	0.10294	0.10297
MAE	0.04652	0.04867	0.04859	0.04890
R^2_{weighted}	0.82590	0.83661	0.83714	0.83703
R^2_{mean}	0.54970	0.55591	0.55845	0.55409

Таблица 1: Полное сравнение режимов regularization на одинаковом тестовом наборе.

Дополнительный анализ формы спектра через ошибки первых и вторых разностей подтверждает ту же картину. Для величины

$$\text{D2-error} = \frac{1}{B(m-2)} \sum_{i=1}^B \sum_{k=1}^{m-2} [(\hat{y}_{i,k+2} - 2\hat{y}_{i,k+1} + \hat{y}_{i,k}) - (y_{i,k+2} - 2y_{i,k+1} + y_{i,k})]^2 \quad (25)$$

получены значения 0.01949 для *Vanilla*, 0.01896 для *Tikhonov-only*, 0.01863 для *SHAP-only* и 0.01893 для основной версии *SHAP + Tikhonov*. Следовательно, регуляризованные варианты в среднем лучше воспроизводят локальную кривизну истинного спектра, однако наилучшее совпадение структуры на этом тесте даёт именно SHAP-регуляризация.

По энергетическим диапазонам сильная комбинированная версия показывает $R^2 = 0.4683$ на бинах $[0, 19]$, 0.6787 на бинах $[20, 39]$ и 0.5152 на бинах $[40, 59]$. *Vanilla* имеет преимущество в низкоэнергетической области, а regularized-варианты лучше восстанавливают среднеэнергетическую часть спектра.

7.2 Вклад регуляризации и интерпретируемость

Для основного запуска `tikhonov_stronger_20260319` средние вклады регуляризаторов в полный функционал составили

$$\mathbb{E}[\gamma_t \tilde{\mathcal{L}}_{\text{SHAP}}^{(t)}] = 5.54 \cdot 10^{-5}, \quad \mathbb{E}[\lambda_{\text{Tikh}} R_{\text{Tikh}}^{(t)}] = 4.23 \cdot 10^{-4}, \quad (26)$$

а средняя доля регуляризации в полном loss достигла

$$\mathbb{E} \left[\frac{\gamma_t \tilde{\mathcal{L}}_{\text{SHAP}}^{(t)} + \lambda_{\text{Tikh}} R_{\text{Tikh}}^{(t)}}{\mathcal{L}_{\text{total}}^{(t)}} \right] = 0.0653. \quad (27)$$

Доминирующим внешним регуляризатором остаётся Tikhonov-член, что естественно для задачи подавления локальной кривизны спектра. При этом SHAP-вклад уже не является символическим и стабильно участвует в донастройке модели.

Адаптивная схема весов выравнивает не сами сырые коэффициенты компонент, а их эффективные взвешенные сигналы. Для *consistency*, *sparsity*, *faithfulness* и *stability* эти сигналы находятся в одном порядке величины, поэтому каждый компонент участвует в формировании итогового SHAP-штрафа, а не добавлен в модель формально.

Сравнение методов: качество, гладкость и вычислительная цена




Рис. 1: Сравнение четырёх режимов по качеству, ошибке кривизны спектра и вычислительной цене.




Рис. 2: Сравнение качества по трём диапазонам энергетических бинов.




Рис. 3: Репрезентативный пример, на котором связка SHAP + Tikhonov даёт более гладкое восстановление спектра, чем Vanilla ANFIS.

Отдельный reduced ablation для сильного SHAP-режима показывает, что не все компоненты одинаково критичны. Удаление *sparsity* сильнее всего ухудшает качество ($R^2_{\text{weighted}} : 0.5133 \rightarrow 0.5115$).

Удаление *consistency* почти не меняет ассигасу, но делает карту важности заметно более схлопнутой: доля top-3 каналов растёт с 0.600 до 0.662, а энтропия падает с 0.886 до 0.847. Поэтому *sparsity* и *consistency* можно интерпретировать как ядро SHAP-регуляризации, тогда как *faithfulness* и *stability* играют вспомогательную роль.

Нормализованная глобальная SHAP-важность образует распределение с единичной суммой. Пять наиболее значимых входных каналов имеют веса

$$Q3 = 0.2693, \quad Q5 = 0.2069, \quad Q6 = 0.1379, \quad Q4 = 0.0957, \quad Q1 = 0.0782. \quad (28)$$

Это подтверждает, что модель выделяет устойчивое ядро информативных детекторов, а не размывает важность равномерно по всем 10 каналам.

7.3 Monte Carlo-анализ устойчивости

Для основной комбинированной версии был проведён Monte Carlo-анализ на репрезентативном входном векторе с $T = 1000$ прогонами и относительным гауссовым шумом 0.5%, 1%, 2%, 5% и 10% на входных каналах. С ростом уровня шума средняя неопределённость восстановленного спектра возрастает монотонно:

$$\text{mean_std} = 5.68 \cdot 10^{-5}, \quad 1.13 \cdot 10^{-4}, \quad 2.25 \cdot 10^{-4}, \quad 5.38 \cdot 10^{-4}, \quad 9.60 \cdot 10^{-4}, \quad (29)$$




Рис. 4: Итоговая нормализованная SHAP-важность входных каналов для основной версии SHAP + Tikhonov.

а максимальная неопределённость по бинам увеличивается от

$$3.59 \cdot 10^{-4} \quad \text{при } 0.5\% \text{ шуме} \quad (30)$$

до

$$5.74 \cdot 10^{-3} \quad \text{при } 10\% \text{ шуме.} \quad (31)$$

Коэффициент вариации также растёт гладко, достигая 0.0497 при 10% шуме. Таким образом, модель сохраняет контролируемую устойчивость даже при существенном ухудшении точности входных измерений.

Однако более важным оказывается межмодельное сравнение на одинаковых 75 реальных тестовых измерениях при 300 Monte Carlo-прогонах на каждый уровень шума. Здесь минимальную чувствительность к входному шуму показывает *Vanilla ANFIS*: при 10% шуме получено $\text{mean_std} = 9.94 \cdot 10^{-4}$ и $\text{max_std} = 9.70 \cdot 10^{-2}$. Для regularized-версий эти величины выше: $1.217 \cdot 10^{-3}$ и $1.252 \cdot 10^{-1}$ у *Tikhonov-only*, $1.227 \cdot 10^{-3}$ и $1.284 \cdot 10^{-1}$ у *SHAP-only*, $1.221 \cdot 10^{-3}$ и $1.255 \cdot 10^{-1}$ у сильной связки *SHAP + Tikhonov*. Среди regularized-вариантов наиболее устойчивым оказывается *Tikhonov-only*, а добавление Tikhonov к SHAP слегка уменьшает неопределённость по сравнению с *SHAP-only*, но не выводит модель на уровень *Vanilla*.

8 Пределы применимости и направления улучшения

С практической точки зрения обе регуляризации разумно применять для спектров, полученных тем же спектрометром и в той же схеме признаков, что использовалась при обучении. Tikhonov-член кодирует физически осмысленный prior гладкости по энергии и потому переносится на реальные измерения достаточно естественно.




Рис. 5: Monte Carlo-оценка устойчивости основной комбинированной версии: рост неопределённости реконструкции и доверительный band для случая 10% шума.




Рис. 6: Сравнение Monte Carlo-устойчивости всех полных режимов на одинаковом наборе real-test измерений.

SHAP-регуляризация более чувствительна к домену данных, так как формирует предпочтительную структуру важности каналов. Поэтому её лучше рассматривать как вспомогательный, а не доминирующий prior.

На held-out real-test наборе остаётся и важное ограничение: у regularized-моделей возникает заметная доля отрицательных бинов в предсказанном спектре (порядка 16%–19% всех значений), тогда как у *Vanilla ANFIS* отрицательные значения отсутствуют. Это означает, что перед переходом к более широкому использованию на настоящих спектрах желательно явно встроить контроль неотрицательности.

С математической точки зрения следующими естественными улучшениями выглядят три направления.

Учет логарифмической шкалы энергии в Tikhonov-члене. Текущий штраф использует обычную вторую разность по номеру бина. Более физичным вариантом является оператор по логарифму энергии $\xi_k = \log E_k$:

$$R_{\text{Tikh}}^{\log} = \frac{1}{B(m-2)} \sum_{i=1}^B \sum_{k=1}^{m-2} \left(\frac{\hat{y}_{i,k+2} - \hat{y}_{i,k+1}}{\Delta \xi_{k+1}} - \frac{\hat{y}_{i,k+1} - \hat{y}_{i,k}}{\Delta \xi_k} \right)^2. \quad (32)$$

Такой вариант должен лучше учитывать неравномерность физической сетки по энергии.

Band-aware SHAP-скаляризация. В текущей реализации SHAP строится по среднему выходу по всем 60 бином. Более информативным может быть скаляризованный функционал

$$s_i^{(\alpha)} = \sum_{b=1}^{B_{\text{band}}} \alpha_b \frac{1}{|I_b|} \sum_{k \in I_b} \hat{y}_{ik}, \quad \alpha_b \geq 0, \quad \sum_b \alpha_b = 1, \quad (33)$$

где веса α_b задают физическую важность диапазонов энергии. Это позволит делать SHAP-регуляризацию чувствительной не только к среднему по спектру, но и к отдельным энергетическим областям.

Явный штраф неотрицательности. Чтобы исключить нефизичные отрицательные значения, можно добавить мягкий барьер

$$R_+ = \frac{1}{Bm} \sum_{i=1}^B \sum_{k=1}^m \max(0, -\hat{y}_{ik})^2. \quad (34)$$

Такой член особенно важен именно для real-world применения, где физическая интерпретация отрицательных потоков невозможна.

Дополнительная проверка с более мягкой комбинированной настройкой $\lambda_{\text{Tikh}} = 10^{-3}$ показала, что долю Tikhonov-регуляризации можно уменьшить примерно с 6.5% до 4.3% и немного улучшить согласование производных спектра, однако это не привело к заметному выигрышу ни над *SHAP-only* по ассурасу, ни над *Tikhonov-only* по Monte Carlo-устойчивости. Следовательно, основной резерв следующей итерации связан не столько с грубой подстройкой коэффициентов, сколько с улучшением самой математической формы регуляризаторов.

9 Выводы

Полученные результаты показывают, что универсального победителя по всем критериям здесь нет. *SHAP-only* оказывается лучшей конфигурацией по основным метрикам ассигасы и по совпадению локальной структуры спектра. *Tikhonov-only* даёт лучшую Monte Carlo-устойчивость среди regularized-вариантов. Полная связка *SHAP + Tikhonov* не даёт драматического прироста относительно *SHAP-only*, но остаётся содержательно важной как компромисс, в котором одновременно присутствуют интерпретируемость каналов и физически мотивированный prior гладкости.

Поэтому текущую двухэтапную схему ANFIS следует рассматривать не как “магическое” доминирование одной сложной модели над всеми остальными, а как гибкую платформу. В ней SHAP и Tikhonov действительно нужны, но решают разные подзадачи: SHAP сильнее помогает качеству и структуре объяснений, Tikhonov — физической гладкости и частично устойчивости внутри regularized-семейства. Следующая итерация метода должна быть направлена на математическое усиление именно этих priors: учет логарифмической шкалы энергии, band-aware SHAP и явное обеспечение неотрицательности спектра.